Projet E4 : Netflix Clustering

Guillaume GAY | Kevin TOULCANON Professeur référent : Victor RABIET



Sommaire

- I. Introduction
- II. Clustering et KMeans
- III. Variante de KMeans : KMedoids
- IV. Classification Naïve Bayésienne
- V. Algorithme E-M
- VI. Conclusion et bilan

I. Introduction

Entreprises produisent beaucoup de données

 Machine Learning et Data Scientist jouent un rôle important



 Apprentissage supervisée et apprentissage non supervisée



Netflix Clustering

II. Clustering et KMeans

KMeans

Trois métriques:

$$d(A, B) = \sqrt{\sum_{i=1}^{n} (a_i - b_i)^2}$$

$$d(A, B) = \sum_{i=1}^{n} |a_i - b_i|$$

$$cos(A, B) = \frac{A \cdot B}{\|A\| \cdot \|B\|} = \frac{\sum_{i=1}^{n} a_i \cdot b_i}{\sqrt{\sum_{i=1}^{n} a_i^2} \sqrt{\sum_{i=1}^{n} b_i^2}}$$

```
INPUT: S, k where S = set of classified instances, k = integer
OUTPUT: k Clusters
Require: S \neq \emptyset, k > 0
 1: procedure GenerateClusters
       initialize k random Centroids
 3:
       repeat
           for all Instance i in S do
              shortest \leftarrow 0
              membership \leftarrow null
              for all Centroid c do
                  dist \leftarrow Distance(c)
                  if dist < shortest then
                      shortest \leftarrow dist
10:
                      membership \leftarrow c
11:
                  end if
12:
              end for
13:
           end for
14:
           RecalculateCentroids(c)
15:
       until convergence
17: end procedure
```


KMeans - fonction fit()


```
21
       def fit(self, X, drawing=False):
22
23
            On effectue un nombre d'itérations fixe défini par self.n iter
24
25
            if not isinstance(X, np.ndarray):
26
               X = np.array(X)
27
28
           # On choisi K points aléatoirement pour être les centroides
29
            self.centroids = X[np.random.choice(len(X), self.K, replace=False)]
30
            self.initial centroids = self.centroids
31
            self.prev label, self.labels = None, np.zeros(len(X))
32
           # On effectue n iter itérations
33
            for i in range(1, self.n iter+1):
                self.prev label = self.labels
34
35
               # On calcule la distance de chaque point aux centroids
36
               # et on affecte un point à la classe ayant le centroide le plus proche
37
                self.labels = self.predict labels(X, self.centroids, self.dist)
38
               # On change le centroide de chaque classe en prenant la moyenne des points de cette classe
39
                self.update centroid(X)
40
41
               if i % 10 == 0: #On plot toutes les 10 itérations
                    self.draw graph(X, i=i, show=drawing)
42
            return self
43
```


KMeans - update_centroid() et predict_labels()

```
45
       def predict labels(self, X, centroids, dist='euc'):
46
            if dist in ['euc', 'll']:
                return self.distance(X, centroids, dist).argmin(axis=1)
47
48
            elif dist=='cos':
49
                return abs(self.distance(X, centroids, dist)).argmin(axis=1)
50
51
       def distance(self, X, centroids, dist='euc'):
52
            map = {'euc':'euclidean', 'cos':'cosine', 'll':'cityblock'}
53
            return sp.spatial.distance.cdist(X, centroids, metric=map[dist])
54
55
       def update centroid(self, X):
56
            self.centroids = np.array([np.mean(X[self.labels == k], axis=0) for k in range(self.K)])
57
           # On pourrait utiliser np.median au lieu de np.mean pour L1
58
59
       def draw graph(self, X, i=0, show=True):
60
            plt.scatter(X[:, 0], X[:, 1], c=self.labels, s=50, cmap='viridis')
61
            plt.scatter(self.centroids[:, 0], self.centroids[:, 1], c='black', s=200, alpha=0.5)
62
            plt.xlabel('x'); plt.ylabel('y'); plt.title(f'Iteration n°{i}')
63
            self.graph = plt.gcf()
           if show: plt.show()
64
65
            else: plt.close(self.graph)
```


Différents tests








Comparaison avec SKlearn




Labels : [0 1 2 3 3 2 1 1 0 0 1 1 2 0 3 1 0 2 3 0]

Inertie: 58.51195436463284




KMeans de SKlearn

[0 1 2 3 3 2 1 1 0 0 3 1 2 0 3 1 0 2 3 0]



KMeans custom

Travail sur des gaussiennes



III. Variante de KMeans : KMedoids

KMedoids

- Reprend le fonctionnement de KMeans
- Les centroids sont forcés d'être des points des données


```
46
        def distance(self, X, centroids, dist='euc'):
47
            map = {'euc':'euclidean', 'cos':'cosine', 'l1':'cityblock'}
48
            return sp.spatial.distance.cdist(X, centroids, metric=map[dist])
49
50
        def update centroid(self, X, dist='euc'):
51
            self.centroids = np.array([np.mean(X[self.labels == k], axis=0) for k in range(self.K)])
52
53
            distances = self.distance(X, self.centroids, dist=dist)
54
            self.centroids = X[distances.argmin(axis=0)]
55
56
        def draw graph(self, X, i=0, show=True):
57
            plt.scatter(X[:, 0], X[:, 1], c=self.labels, s=50, cmap='viridis')
58
            plt.scatter(self.centroids[:, 0], self.centroids[:, 1], c='black', s=200, alpha=0.5)
59
            plt.xlabel('x'); plt.ylabel('y'); plt.title(f'Iteration n°{i}')
            self.graph = plt.gcf()
60
61
            if show: plt.show()
            else: plt.close(self.graph)
62
```

KMedoids

```
kmed = KMedoids(n_clusters=3, n_iter=100, dist='euc')
kmed.fit(df_X, drawing=False)
kmed.labels
```

array([0, 0, 0, 0, 0, 0, 2, 2, 2, 2, 2, 2, 1, 1, 1, 1, 1, 1])

1 kmed.graph



IV. Classification Naïve Bayésienne


Plusieurs étapes :


• Étape 1 : Le compte des mots

• Étape 2 : Calcul des probabilités

• Étape 3: Test de la classification









Étape 1

```
def freqMots(df):
    1 = []
    dic = {}
    for e in df.itertuples():
        1.append(e[1])
    L = traitement_texte(1)
    for phr in L: #création du dictionnaire
        mots = nltk.word_tokenize(phr)
        for mot in mots:
            if mot not in dic.keys():
                dic[mot] = 1
            else:
                dic[mot] += 1
    return dic
```

Étape 2

```
def conditionnal_prob(dic):
        fonction qui va calculer les probabilités conditionnelles de chaque mot selon la classe dont elle appartient
    dpos_prob = {} #dictionnaire qui contiendra les probabilités du vocabulaire pour la classe pos
    dneg_prob = {} #dictionnaire qui contiendra les probabilités du vocabulaire pour la classe neg
    a = 0
    for cle, valeur in dic.items():
        if cle in dic pos:
            a = (dic pos[cle]+1.0)/(nbr mots pos+1) #utilisation de la formule
            dpos prob[cle]=a
        else: #si le mot n'appartient pas à la classe
            a = 1.0/(nbr mots pos+1)
            dpos prob[cle]=a
        if cle in dic_neg:
            a = (dic_neg[cle]+1.0)/(nbr_mots_neg+1)
           dneg_prob[cle]=a
        else:
            a = 1.0/(nbr_mots_neg+1)
            dneg_prob[cle]=a
    return dpos prob, dneg prob
```

Étape 3

```
#compte des mots
   mots = L[i].split()
    compte = {}.fromkeys(set(mots),0)
    for valeur in mots:
        compte[valeur] += 1
    #Propriétés d'appartenir à la classe pos ou neg
    pp = np.log(0.5) #0.5 est une prior probability pour la classe pos
    pn = np.log(0.5) #0.5 est une prior probability pour la classe neg
    for cle in compte.keys():
        if cle in dic:
            pp+=np.log(dpos prob[cle]**(compte[cle]))
            #en puissance compte[cle] correspond à la fréquence du mot dans le document
        if cle in dic:
            pn+=np.log(dneg prob[cle]**(compte[cle]))
    Lp.append(pp)
    Ln.append(pn)
for i in range(len(Lp)):
    if(Lp[i]>Ln[i]):
        1.append('pos')
   else:
        1.append('neg')
return 1
```

Résultat

 81.5 % prédictions justes données anglaises : 90% pour la classe neg et 73% pour la classe pos

• 71.5% prédictions justes données françaises



V. Algorithme E-M

Deux étapes :

• Étape E : Calcul de la vraisemblance des données

 Étape M : Maximisation de la vraisemblance et actualisation des paramètres

• Itérations tant que la log-vraisemblance varie significativement

Étape E

```
estep(X: np.ndarray, mixture: GaussianMixture) -> Tuple[np.ndarray, float]:
"""E-step: Softly assigns each datapoint to a gaussian component
Args:
   X: (n, d) array holding the data
   mixture: the current gaussian mixture
Returns:
    np.ndarray: (n, K) array holding the soft counts
        for all components for all examples
    float: log-likelihood of the assignment
n, d = X.shape
K = mixture.mu.shape[0]
densite = np.zeros([n, K])
posterior = np.zeros([n, K])
for i in range(K):
    densite[:,i] = multivariate normal.pdf(X, mixture.mu[i,:], mixture.var[i])
    # P(x i|theta) - loi à posteriori
    posterior[:,i] = densite[:,i]*mixture.p[i]
vraisemblance = np.sum(posterior, axis=1)
post = posterior / vraisemblance[:,None]
log vraisemblance = np.log(posterior.sum(axis=1)).sum()
return post, log vraisemblance
```


Étape M


```
def mstep(X: np.ndarray, post: np.ndarray) -> GaussianMixture:
    """M-step: Updates the gaussian mixture by maximizing the log-likelihood
   of the weighted dataset
   Args:
       X: (n, d) array holding the data
       post: (n, K) array holding the soft counts
           for all components for all examples
   Returns:
       GaussianMixture: the new gaussian mixture
   d = X.shape[1]
   K = post.shape[1]
   mu = np.zeros([K, d])
   sigma = np.zeros(K)
   # p est la moyenne des p(j|i)
   p = post.mean(axis=0)
   for i in range(K):
       mu[i,:] = (post[:,i] @ X)/post[:,i].sum()
       sigma[i] = ((post[:,i] @ (X - mu[i,:])**2) / post[:,i].sum()).mean()
   return GaussianMixture(mu, sigma, p)
```

Itérations


```
def run(X: np.ndarray, mixture: GaussianMixture,
       post: np.ndarray) -> Tuple[GaussianMixture, np.ndarray, float]:
    """Runs the mixture model
   Args:
       X: (n, d) array holding the data
       post: (n, K) array holding the soft counts
            for all components for all examples
   Returns:
       GaussianMixture: the new gaussian mixture
       np.ndarray: (n, K) array holding the soft counts
            for all components for all examples
       float: log-likelihood of the current assignment
   gauss mixture = mixture
   old log vraisemblance = np.inf
    log vraisemblance = 0
   while abs(old log vraisemblance - log vraisemblance) > 1e-6*abs(log vraisemblance):
       old log vraisemblance = log vraisemblance
       post, log vraisemblance = estep(X, gauss mixture)
       gauss mixture = mstep(X, post)
    return gauss mixture, post, log vraisemblance
```


Résultats





Résultats





Conclusion et bilan